

- Regresión lineal.  $\rightarrow$  Problemas de clasificación.  $\rightarrow$  Parto de un conjunto de datos, para encontrar el mejor modelo.
- Aprendizaje Supervisado: problemas de regresión.

$$(x^i, y^i) \rightarrow \alpha^i = (\alpha_1^i, \alpha_2^i, \alpha_3^i, \dots) \mid i=1, \dots, m$$

$\alpha^i$  = muestra  
 $\alpha_j^i$  = atributo  
 $y^i$  = continuo

EJ: Precio Vivienda.

- Vamos a suponer que existe una relación lineal entre  $x$  e  $y$ .

$\rightarrow$  Hipótesis:  $h_w(x) = \underbrace{x_0 \cdot w_0}_{w_0} + \alpha_1 \cdot w_1 + \alpha_2 \cdot w_2 + \dots + \alpha_n \cdot w_n$

$\hookrightarrow w$  = vector de pesos

$$h_w(x) = \sum_k \alpha_k \cdot w_k$$

- ¿Y cómo calculamos los pesos?

Definir una función  $d(\vec{w}) = \frac{1}{2m} \cdot \sum_i (y^i \cdot h_w(\alpha^i))^2$  para encontrar el error que comete  $\vec{w}$ .

$\rightarrow$  error en el ejemplo  $i$  por  $h_w(\alpha^i)$   
 $\rightarrow$  dato en un puto ejemplo.

"Función de Costo"  
 $\hookrightarrow$  para establecer un valor  $\alpha$  y  $w$  que se acerque a lo esperado

$\hookrightarrow$  "error cuadrático medio" ECM

"Coeficiente de Correlación"  
 $\rightarrow$  Objetivo (que se acerque).  
 $\hookrightarrow$  Min/Max  $d(\vec{w})$


- Una vez tenemos nuestra ecuación de coste, es importante saber cuando nos acercamos a los valores con un mínimo de error.

Para ello, introducimos el término de gradiente descendiente.

Método del gradiente descendiente.

- Pretende encontrar un mínimo de la función.

$$\frac{dd(\vec{w})}{d\vec{w}} = \left( \frac{\partial d(\vec{w})}{\partial w_0}, \dots, \frac{\partial d(\vec{w})}{\partial w_n} \right)$$



## Ejemplo

DataSet

$\alpha_i$	$y$
1	1
3	2
4	5

$\alpha = 0,1 \rightarrow$  Valor alpha (valor cualquiera)

$w = (0, 0,25) \rightarrow$  Vector Inicial

$w_0$   $w_1$

1) Hipótesis inicial  $\rightarrow h_{\vec{w}}(\vec{\alpha}) = 0 + 0,25\alpha_i$

• Gradiente Decreciente  $\rightarrow$

$\alpha_0$	$\alpha_1$	$y$	$\hat{y}$	error cometido $y - \hat{y}$	*
1	1	1	0,25 $\rightarrow h_{\vec{w}}(\vec{\alpha}) = 0 \cdot \alpha_0 + 0,25 \cdot 1$	0,75	
1	3	2	0,75 $\rightarrow \text{"} = 0 \cdot \alpha_0 + 0,25 \cdot 3$	1,25	
1	4	5	1 $\rightarrow \text{"} = 0 \cdot \alpha_0 + 0,25 \cdot 4$	4	

$\delta_0 =$  error gradiente eje  $\alpha_0$   $\delta_1 =$  error gradiente eje  $\alpha_1$

*	$(y - \hat{y}) \cdot \alpha_0$	$(y - \hat{y}) \cdot \alpha_1$
	0,75	0,75
	1,25	3,75
	4	16

$$\delta_0 = \frac{6}{3} = 2$$

$$\delta_1 = \frac{20,5}{3} = 6,83$$

$$w_0 \leftarrow w_0 + \alpha \cdot \delta_0 = 0 + 0,1 \cdot 2 = 0,2$$

$$w_1 \leftarrow w_1 + \alpha \cdot \delta_1 = 0,25 + 0,1 \cdot 6,83 = 0,933$$

2) Nueva Hipótesis

$$\rightarrow h_{\vec{w}}(\vec{\alpha}) = 0,2 \cdot \alpha_0 + 0,933 \cdot \alpha_1$$

$\rightarrow$  (Volvemos a hacer lo mismo).